

Quatitative Methoden der Informatik

Zusammenfassung und Lernzettel

Kompakte Zusammenfassung der Vorlesungsinhalte für die Prüfungsvorbereitung.

Autor Levin Rüßmann
Matrikelnummer 838791
Studiengang Informatik B.Sc.
Semester Sommersemester 2026
Datum 20.07.2026

Inhaltsverzeichnis

1 Grundbegriffe	3
1.1 Hypothese	3
1.2 Modell	3
1.3 Schlusstechniken	3
1.3.1 Induktion	3
1.3.2 Deduktion	3
1.3.3 Abduktion	3
1.4 Gütekriterien	3
1.4.1 Ethische Aspekte	3
1.4.2 Transparenz	3
1.4.3 Objektivität	3
1.4.4 Interne Validität	4
1.4.5 Externe Validität	4
1.5 Forschungsmethoden	4
1.5.1 Quantitative Methoden	4
1.5.2 Qualitative Methoden	4
1.6 Stichprobe	4
1.6.1 Zufallsstichprobe (Random Sample)	4
1.6.2 Klumpenstichprobe (Cluster Sample)	4
2 Deskriptive Statistik	5
2.1 Lagemaße	5
2.1.1 Median	5
2.1.2 Modus	5
2.1.3 Mittelwert	5
2.1.4 MAD	5
2.1.5 Quartile	5
2.1.6 Quartile berechnen	5
2.2 Streuungsmaße	6
2.2.1 Spannweite	6
2.2.2 Interquartilsabstand – IQR	6
2.2.3 Standardabweichung	6
2.2.4 Varianz	6
2.3 Zusammenhangsmaße	7
2.3.1 Korrelation	7
2.3.2 Kovarianz	7
2.3.3 r-Wert – Korrelationskoeffizient	7
2.4 Diagramme	8
2.4.1 Box-Plot	8
2.4.2 Säulendiagramm / Balkendiagramm	8
2.4.3 Streudiagramm / Scatterplot	9
3 Zufalls Variablen	10
4 Normalverteilung	11
4.1 Rechnen mit der Normalverteilung	12
4.2 Normalverteilungstabelle	13

5 Inferenzstatistik	14
5.1 Chi-Quadrat-Test	14
5.1.1 Hypothesen	14
5.1.2 Die Formel	14
5.1.3 Freiheitsgrade	14
5.1.4 Kritischer Wert und Entscheidung	15
5.1.5 Ablauf in der Klausur	15
6 R	17
6.1 Grundlagen	17
6.1.1 Datenhandling	17
6.1.2 Rechnen	17
6.1.3 Logik	18
6.2 Datenanalyse	18
6.2.1 Grafische Verfahren	18
6.2.2 Kennzahlen	18
6.3 Grafik mit ggplot2	19
6.3.1 Geometrien (<code>geom_</code>)	19
6.3.2 Bausteine (Layer)	20
6.3.3 Ästhetik-Zuordnungen (<code>aes</code>)	20
6.4 Verteilungen & Simulation	20
6.4.1 Normalverteilung	20
6.4.2 Randomisierung & Simulation	21
6.5 Modellierung	21
6.6 Inferenz	21
6.7 Daten einlesen	22
6.8 Tidyverse	22
6.8.1 Historie	22
6.8.2 Kern-Pakete	22
7 Taschenrechner: Casio fx-991DE X ClassWiz	24
7.1 Stichprobe und Kennwerte (Menü 6: Statistik)	25
7.1.1 Stichprobe eingeben	25
7.1.2 Kennwerte ablesen	25
7.2 Tabellenkalkulation (Menü 8)	26
7.2.1 Werte eingeben und auswerten	26
7.2.2 Eigene Formeln und „Formel füllen“	27
7.3 Lineare Regression und Korrelation (Menü 6: $y=a+bx$)	27
7.4 Normalverteilung (Menü 7: Verteilungsfkt.)	28
7.5 Chi-Quadrat mit der Tabellenkalkulation	30
8 Formelsammlung	31
8.1 Deskriptive Statistik	31
8.1.1 Lage- und Streuungsmaße	31
8.1.2 Quantile	31
8.1.3 Zusammenhangsmaße	31
8.2 Wahrscheinlichkeit & Normalverteilung	32
8.3 Inferenzstatistik – Chi-Quadrat-Test	32
8.4 Normalverteilungstabelle	32

1 Grundbegriffe

Informationen vorab

Dies ist eine Sammlung von Begriffen, die uns im Studium immer wieder begegnen werden, also nicht nur für die Klausur in Quantitative Methoden der Informatik. Für die Personen, welche die Probeklausuren nicht kennen: In der Klausur werden insbesondere die **Gütekriterien** und **Stichprobe** eine Rolle spielen.

1.1 Hypothese

Eine Hypothese ist eine Aussage, abgeleitet aus einer Theorie oder einer Beobachtung. Hypothesen sind nicht so umfangreich wie eine Theorie und stellen eine Vermutung zu einem Sachverhalt auf. Sie sind überprüfbar und können bestätigt bzw. bewiesen werden. Wissenschaftliche Hypothesen prüfen Zusammenhänge.

1.2 Modell

Modelle sind vereinfachte Darstellungen relevanter Teile der Realität. Die Repräsentation der Realität durch Modelle ermöglicht eine einfachere Analyse.

1.3 Schlusstechniken

1.3.1 Induktion

Generalisierung von in der Realität beobachteten Regelmäßigkeiten zu einer allgemeineren Vermutung.

1.3.2 Deduktion

Ableitung von Aussagen aus anderen (allgemeineren) Aussagen mit Hilfe logischer Regeln.

1.3.3 Abduktion

Verknüpfung von Einzelbeobachtungen und Erkennen (Vermuten) von Regeln.

1.4 Gütekriterien

Die Gütekriterien beschäftigen sich damit, was eine gute Forschung ausmacht. Wenn diese nicht eingehalten sind, wird eine Arbeit nicht als besonders gut angesehen.

1.4.1 Ethische Aspekte

Bei den ethischen Aspekten ist es wichtig, eine bestimmte Ethik einzuhalten. Also, ob durch eine Forschung eventuell Schaden für die Umwelt, Befragte oder untersuchte Personen entsteht. Dazu gehört auch der Datenschutz der Teilnehmer*innen einer Forschung.

1.4.2 Transparenz

Bei Forschung, insbesondere bei Befragungen und Experimenten, sollte die Vorgehensweise gut dokumentiert sein. Die Dokumentation sollte so gut sein, dass andere Forscher*innen ein Experiment oder eine Umfrage replizieren könnten, um die Forschung zu überprüfen.

1.4.3 Objektivität

Es soll geprüft werden, ob das Forschungsergebnis unabhängig von anderen Personen ist, indem geschaut wird, ob andere Personen zum selben Ergebnis kommen. Themen, die in einer Arbeit behandelt werden, sollten auch objektiv behandelt werden, ohne eine starre Sicht einzunehmen.

1.4.4 Interne Validität

Wenn man eine Umfrage oder eine Forschung durchgeführt hat, sollte man immer schauen, ob das Ergebnis durch die Forschungsmethode zustande kommt oder ob das Ergebnis vielleicht von anderen Faktoren beeinflusst wurde.

1.4.5 Externe Validität

Es wird geprüft, ob behauptete Zusammenhänge auch auf andere Situationen übertragbar sind.

1.5 Forschungsmethoden

1.5.1 Quantitative Methoden

Bei quantitativen Forschungen geht es darum, eine These durch Datenerhebung zu prüfen. Hierbei wird versucht, die Wirklichkeit durch numerische Messungen darzustellen. Auf den Skalen wird ein Ausschnitt aus den Befragungen abgebildet. Es wird mit Häufigkeiten, Mittelwerten, Wahrscheinlichkeiten des Auftretens von Ausprägungen gearbeitet. **Beispiele:**

- Online-Umfragen
- A/B-Test auf Webseiten
- Auswertung von Log-Daten
- Zählung, wie viele von 300 Befragten ein bestimmtes Betriebssystem nutzen.

1.5.2 Qualitative Methoden

Bei qualitativen Methoden wird versucht, eine Wirklichkeit darzustellen bzw. zu verbalisieren. Wirklichkeitsinterpretationen sind durch spezifische soziale Handlungsweisen geprägt und strukturieren gleichzeitig das soziale Handeln der Einzelperson vor. Der Untersuchungsgegenstand soll möglichst in seinem natürlichen Umfeld detailliert, ganzheitlich und umfassend erfasst werden. **Beispiele:**

- Ein leitfadengestütztes Interview mit 8 Entwicklern, in dem du fragst „Warum benutzt ihr Tool X lieber als Y?“, und die Antworten anschließend codierst.
- Eine Gruppendiskussion (Fokusgruppe), in der du beobachtest, wie ein Team über ein neues Software-Feature spricht.
- Teilnehmende Beobachtung: Du sitzt eine Woche in einem Support-Team und dokumentierst, wie sie mit Kundenanfragen umgehen.

1.6 Stichprobe

Es wird nur ein kleiner Teil der Grundgesamtheit untersucht. Aus diesem Teil zieht man Rückschlüsse auf die gesamte Grundgesamtheit.

1.6.1 Zufallsstichprobe (Random Sample)

Die Personen werden vollständig zufällig ausgewählt, ohne Kriterien. Jedes Element hat dieselbe Wahrscheinlichkeit, gezogen zu werden.

1.6.2 Klumpenstichprobe (Cluster Sample)

Die Grundgesamtheit wird in Klumpen (Cluster) zerlegt, z. B. nach Filialen oder Stadtteilen. Einige Klumpen werden zufällig gezogen und darin werden alle Personen befragt.

2 Deskriptive Statistik

Deskriptive Statistik bedeutet, dass man versucht, Daten durch Tabellen, Kennzahlen und Grafiken übersichtlich darzustellen und zu ordnen.

2.1 Lagemaße

2.1.1 Median

Der Median ist der mittlere Wert der sortierten Werte. Bei einer geraden Anzahl von Werten nimmt man die zwei mittelsten Werte, addiert diese und teilt sie durch 2. Bei einer ungeraden Anzahl nimmt man den mittleren Wert.

2.1.2 Modus

Der Modus ist der Wert, der am häufigsten vorkommt. Es kann mehrere Modi geben, dann ist die Verteilung multimodal.

2.1.3 Mittelwert

Der Mittelwert gibt den durchschnittlichen Wert an.

Formel:

$$\text{Mittelwert} = \frac{\sum_{i=1}^n x_i}{n}$$

2.1.4 MAD

MAD steht für Mittlere Absolute Abweichung.

Formel:

$$\text{MAD} = \frac{\sum_{i=1}^n |\text{Mittelwert} - x_i|}{n}$$

2.1.5 Quartile

Die Quartile basieren darauf, dass du deine Daten der Größe nach sortierst. Danach schneidest du die Reihe in vier gleich große Teile, also vier Viertel. Die Schnittstellen sind die Quartile.

- Q_1 (unteres Quartil): Unterhalb dieses Wertes liegen 25 % aller Daten.
- Q_2 (mittleres Quartil): Das ist genau der Median, 50 % liegen darunter.
- Q_3 (oberes Quartil): Unterhalb liegen 75 % aller Daten, also nur noch 25 % darüber.

Wichtig

Ein Quartil ist ein Ort auf der Zahlenachse, kein Anteil.

2.1.6 Quartile berechnen

Zuerst werden alle Werte **aufsteigend sortiert**. Dabei ist n die Anzahl der Elemente und $x_{(i)}$ der Wert an Position i der sortierten Liste.

$$x_p = \begin{cases} x_{(\lceil n \cdot p \rceil)} & \text{falls } n \cdot p \notin \mathbb{Z} \\ \frac{1}{2} \cdot (x_{(n \cdot p)} + x_{(n \cdot p + 1)}) & \text{falls } n \cdot p \in \mathbb{Z} \end{cases}$$

Quartil 1 (unteres Quartil, $p = 0.25$):

$$Q_1 = \begin{cases} x_{(\lceil 0.25 \cdot n \rceil)} & \text{falls } 0.25 \cdot n \notin \mathbb{Z} \\ \frac{1}{2} \cdot (x_{(0.25 \cdot n)} + x_{(0.25 \cdot n + 1)}) & \text{falls } 0.25 \cdot n \in \mathbb{Z} \end{cases}$$

Quartil 3 (oberes Quartil, $p = 0.75$):

$$Q_3 = \begin{cases} x_{(\lceil 0.75 \cdot n \rceil)} & \text{falls } 0.75 \cdot n \notin \mathbb{Z} \\ \frac{1}{2} \cdot (x_{(0.75 \cdot n)} + x_{(0.75 \cdot n + 1)}) & \text{falls } 0.75 \cdot n \in \mathbb{Z} \end{cases}$$

2.2 Streuungsmaße

2.2.1 Spannweite

Der Abstand zwischen dem kleinsten und dem größten Wert.

2.2.2 Interquartilsabstand – IQR

$$\text{IQR} = Q_3 - Q_1$$

Der IQR ist ein Streuungsmaß, genau wie Varianz oder Standardabweichung. Er beantwortet die Frage: „Wie breit ist der Bereich, in dem die mittlere Hälfte meiner Daten liegt?“

2.2.3 Standardabweichung

Die Standardabweichung ist einfach die Wurzel aus der Varianz. Sie gibt an, wie stark die Werte im Schnitt vom Mittelwert abweichen, aber wieder in der ursprünglichen Einheit (nicht quadriert wie bei der Varianz). **Formel:**

$$S = \sqrt{S^2}$$

Kann auch mit σ dargestellt werden.

2.2.4 Varianz

Varianz ist ein Maß dafür, wie stark die Werte einer Datenreihe im Durchschnitt von ihrem Mittelwert abweichen. Sie beschreibt also die Streuung der Daten. Die Varianz wird bei Einheiten (z. B. cm) quadriert angegeben, also in cm^2 . **Formel:**

$$S^2 = \frac{\sum_{i=1}^n (x_i - \text{Mittelwert})^2}{n}$$

Kann auch mit σ^2 dargestellt werden.

2.3 Zusammenhangsmaße

2.3.1 Korrelation

Eine Korrelation beschreibt eine Beziehung zwischen zwei oder mehreren Merkmalen, Zuständen oder Funktionen.




Abbildung 1. Korrelation

2.3.2 Kovarianz

Misst, wie zwei Variablen gemeinsam um ihren Mittelwert streuen (positiv = gleichläufig, negativ = gegenläufig).

2.3.3 r-Wert – Korrelationskoeffizient

Der Korrelationskoeffizient r misst Stärke und Richtung eines linearen Zusammenhangs zweier metrischer Variablen, $-1 \leq r \leq +1$. Der Betrag $|r|$ gibt die Stärke an (nahe 1 stark, nahe 0 schwach), das Vorzeichen die Richtung.

2.4 Diagramme

2.4.1 Box-Plot

Ein Box-Plot ist ein Diagramm zur grafischen Darstellung von Minimum, Maximum, Median und den Quartilen.

Durch den Box-Plot erhält man einen schnellen Überblick über die Werte.




Abbildung 2. Box-Plot

2.4.2 Säulendiagramm / Balkendiagramm

Häufigkeit von Merkmalsausprägungen (nominal, ordinal, metrisch diskret).




Abbildung 3. Säulendiagramm

2.4.3 Streudiagramm / Scatterplot

Darstellung der Merkmalsausprägungen von zwei i.d.R. metrischen Merkmalen. Bei kategorialen oder metrisch diskreten Merkmalen ggfs. verwackeln.




Abbildung 4. Streudiagramm

3 Zufalls Variablen

Eine Zufallsvariable X ist eine Variable, deren Wert x vom Zufall abhängt. Zufalls Variablen könne auch die Brenndauer einer LED sein, da es extrem viele einfluss faktoren auf die Brenndauer gibt so dass man das ende nicht klar bestimmen kann.

Realisation einer Zufalls Variablen

Beobachtungen x_i können aufgefasst werden als Realisationen von Zufallsvariablen X .

4 Normalverteilung

Zentraler Grenzwertsatz

Fast jeder Mittelwert einer x -beliebigen Verteilung – stetig oder diskret – folgt der Normalverteilung.

Die Normalverteilung wird auch Gauß-Verteilung bzw. Glockenkurve genannt. Der Grund, warum sie so genannt wird, ist am Plot gut zu erkennen.




Abbildung 5. Normalverteilung

Die Normalverteilung hängt vom Erwartungswert μ – bzw. dem Mittelwert – und von der Varianz σ^2 ab. Der Erwartungswert verschiebt die Kurve nach links oder rechts, die Varianz beeinflusst die Form der Kurve: Sie ist entweder gestreckt oder gestaucht.

4.1 Rechnen mit der Normalverteilung

Warnung

Für die Normalverteilung gibt es eigentlich zwei wichtige Funktionen, um eine Wahrscheinlichkeit auszurechnen. Die müssen wir nicht können! Ich liste sie nur der Vollständigkeit halber auf – ist ja nice to know.

Dichtefunktion

Die Dichtefunktion beschreibt, wie dicht die Wahrscheinlichkeit an einer bestimmten Stelle x verteilt ist. Bildlich gesprochen: die Höhe der Glockenkurve an dieser Stelle.

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

Verteilungsfunktion

Die Verteilungsfunktion gibt dir direkt die kumulierte Wahrscheinlichkeit $P(X \leq x)$ an, also die gesamte Fläche unter der Dichtekurve von minus unendlich bis zu diesem Punkt x .

$$F(x) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(u-\mu)^2}{2\sigma^2}} du$$

z-Transformation

Damit wir diese Formeln nicht lernen müssen, gibt es die Transformationsfunktion. Hier wird eine beliebige Verteilung in eine Verteilung mit $\sigma = 1$ und $\mu = 0$ transformiert. Die Formel ist für uns wichtig, da wir dadurch die Normalverteilungstabelle nutzen können.

$$z = \frac{x - \mu}{\sigma}$$

Das Ergebnis der z-Transformation können wir dann durch einen Plot wie folgt darstellen.




Abbildung 6. Wahrscheinlichkeit bei Normalverteilung

4.2 Normalverteilungstabelle

Die Normalverteilungstabelle wird uns in der Klausur bereitgestellt. Ich führe sie nur noch mal auf.

Negativen Wert berechnen

$$\Phi(-u) = 1 - \Phi(u)$$

Tabelle

u	0,00	0,01	0,02	0,03	0,04	0,05	0,06	0,07	0,08	0,09	u
0,0	0,5000	0,5040	0,5080	0,5120	0,5160	0,5199	0,5239	0,5279	0,5319	0,5359	0,0
0,1	0,5398	0,5438	0,5478	0,5517	0,5557	0,5596	0,5636	0,5675	0,5714	0,5753	0,1
0,2	0,5793	0,5832	0,5871	0,5910	0,5948	0,5987	0,6026	0,6064	0,6103	0,6141	0,2
0,3	0,6179	0,6217	0,6255	0,6293	0,6331	0,6368	0,6406	0,6443	0,6480	0,6517	0,3
0,4	0,6554	0,6591	0,6628	0,6664	0,6700	0,6736	0,6772	0,6808	0,6844	0,6879	0,4
0,5	0,6915	0,6950	0,6985	0,7019	0,7054	0,7088	0,7123	0,7157	0,7190	0,7224	0,5
0,6	0,7257	0,7291	0,7324	0,7357	0,7389	0,7422	0,7454	0,7486	0,7517	0,7549	0,6
0,7	0,7580	0,7611	0,7642	0,7673	0,7704	0,7734	0,7764	0,7794	0,7823	0,7852	0,7
0,8	0,7881	0,7910	0,7939	0,7967	0,7995	0,8023	0,8051	0,8079	0,8106	0,8133	0,8
0,9	0,8159	0,8186	0,8212	0,8238	0,8264	0,8289	0,8315	0,8340	0,8365	0,8389	0,9
1,0	0,8413	0,8438	0,8461	0,8485	0,8508	0,8531	0,8554	0,8577	0,8599	0,8621	1,0
1,1	0,8643	0,8665	0,8686	0,8708	0,8729	0,8749	0,8770	0,8790	0,8810	0,8830	1,1
1,2	0,8849	0,8869	0,8888	0,8907	0,8925	0,8944	0,8962	0,8980	0,8997	0,9015	1,2
1,3	0,9032	0,9049	0,9066	0,9082	0,9099	0,9115	0,9131	0,9147	0,9162	0,9177	1,3
1,4	0,9192	0,9207	0,9222	0,9236	0,9251	0,9265	0,9279	0,9292	0,9306	0,9319	1,4
1,5	0,9332	0,9345	0,9357	0,9370	0,9382	0,9394	0,9406	0,9418	0,9429	0,9441	1,5
1,6	0,9452	0,9463	0,9474	0,9484	0,9495	0,9505	0,9515	0,9525	0,9535	0,9545	1,6
1,7	0,9554	0,9564	0,9573	0,9582	0,9591	0,9599	0,9608	0,9616	0,9625	0,9633	1,7
1,8	0,9641	0,9649	0,9656	0,9664	0,9671	0,9678	0,9686	0,9693	0,9699	0,9706	1,8
1,9	0,9713	0,9719	0,9726	0,9732	0,9738	0,9744	0,9750	0,9756	0,9761	0,9767	1,9
2,0	0,9773	0,9778	0,9783	0,9788	0,9793	0,9798	0,9803	0,9808	0,9812	0,9817	2,0
2,1	0,9821	0,9826	0,9830	0,9834	0,9838	0,9842	0,9846	0,9850	0,9854	0,9857	2,1
2,2	0,9861	0,9864	0,9868	0,9871	0,9875	0,9878	0,9881	0,9884	0,9887	0,9890	2,2
2,3	0,9893	0,9896	0,9898	0,9901	0,9904	0,9906	0,9909	0,9911	0,9913	0,9916	2,3
2,4	0,9918	0,9920	0,9922	0,9925	0,9927	0,9929	0,9931	0,9932	0,9934	0,9936	2,4
2,5	0,9938	0,9940	0,9941	0,9943	0,9945	0,9946	0,9948	0,9949	0,9951	0,9952	2,5
2,6	0,9953	0,9955	0,9956	0,9957	0,9959	0,9960	0,9961	0,9962	0,9963	0,9964	2,6
2,7	0,9965	0,9966	0,9967	0,9968	0,9969	0,9970	0,9971	0,9972	0,9973	0,9974	2,7
2,8	0,9974	0,9975	0,9976	0,9977	0,9977	0,9978	0,9979	0,9979	0,9980	0,9981	2,8
2,9	0,9981	0,9982	0,9983	0,9983	0,9984	0,9984	0,9985	0,9985	0,9986	0,9986	2,9

Quantiltabelle

p	0,8	0,9	0,95	0,975	0,98	0,99	0,995
u_p	0,84162	1,28155	1,6449	1,9600	2,0538	2,3264	2,5758

5 Inferenzstatistik

Die deskriptive Statistik beschreibt die Daten, die man hat. Die Inferenzstatistik geht einen Schritt weiter: Sie schließt von einer Stichprobe auf die Grundgesamtheit und prüft Hypothesen – also Fragen wie „Ist dieser Würfel fair?“ oder „Ist diese Abweichung noch Zufall?“.

5.1 Chi-Quadrat-Test

Der Chi-Quadrat-Test vergleicht **beobachtete** Häufigkeiten mit den Häufigkeiten, die man unter einer angenommenen Verteilung **erwarten** würde. Er beantwortet die Frage: Sind die Abweichungen zwischen Beobachtung und Erwartung noch zufällige Schwankung – oder so groß, dass die Annahme nicht stimmen kann?

5.1.1 Hypothesen

Wie jeder Hypothesentest beginnt der Chi-Quadrat-Test mit zwei Hypothesen:

- H_0 (Nullhypothese): Die Daten folgen der erwarteten Verteilung, Abweichungen sind reiner Zufall. Beispiel: „Der Würfel ist fair.“
- H_1 (Gegenhypothese): Die Daten folgen der erwarteten Verteilung nicht. Beispiel: „Der Würfel ist manipuliert.“

Der Test kann H_0 nur **verwerfen** oder **nicht verwerfen** – beweisen kann er sie nicht.

5.1.2 Die Formel

$$\chi^2 = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i}$$

Zeichen	Bedeutung
O_i	beobachtete Häufigkeit (<i>observed</i>) in Kategorie i
E_i	erwartete Häufigkeit (<i>expected</i>) in Kategorie i : $E_i = n \cdot p_i$
k	Anzahl der Kategorien (z. B. 6 Augenzahlen)
n	Gesamtzahl der Beobachtungen

So liest du die Formel: Für jede Kategorie wird die Abweichung $O_i - E_i$ gebildet und **quadriert** – dadurch zählen positive und negative Abweichungen gleich viel und heben sich nicht gegenseitig auf. Die Division durch E_i setzt die Abweichung ins Verhältnis zur Erwartung: Eine Abweichung von 5 ist bei $E_i = 5$ dramatisch, bei $E_i = 500$ fast nichts. Zum Schluss wird über alle Kategorien summiert. Je größer χ^2 , desto schlechter passen Beobachtung und Erwartung zusammen – bei perfekter Übereinstimmung ist $\chi^2 = 0$.

5.1.3 Freiheitsgrade

$$df = k - 1$$

Die Zahl der Freiheitsgrade (*degrees of freedom*, df) ist die Anzahl der Kategorien minus 1.

Warum minus 1?

Freiheitsgrade sind die Anzahl der **frei wählbaren** Werte. Die Gesamtzahl n steht fest – und damit auch die Summe aller Häufigkeiten. Bei 6 Kategorien kannst du also nur 5 Felder frei befüllen; das letzte ergibt sich zwangsläufig als Rest. Deshalb $df = 6 - 1 = 5$.

5.1.4 Kritischer Wert und Entscheidung

Der kritische Wert χ^2_{krit} ist die Schwelle, ab der eine Abweichung nicht mehr als Zufall durchgeht. Du liest ihn aus der Chi-Quadrat-Tabelle ab (sie wird in der Klausur gestellt), und zwar an der Kreuzung von zwei Angaben:

- dem **Signifikanzniveau** α – meist $\alpha = 0,05$, also 5 % Irrtumswahrscheinlichkeit. Das ist das Risiko, H_0 zu verwerfen, obwohl sie eigentlich stimmt.
- den **Freiheitsgraden** df aus dem letzten Abschnitt.

Entscheidungsregel

$\chi^2 > \chi^2_{\text{krit}} \rightarrow H_0$ verwerfen: Die Abweichung ist signifikant.
 $\chi^2 \leq \chi^2_{\text{krit}} \rightarrow H_0$ nicht verwerfen: kein Nachweis einer Abweichung.

5.1.5 Ablauf in der Klausur

- 1 Hypothesen aufstellen: H_0 (erwartete Verteilung gilt) und H_1 .
- 2 Erwartete Häufigkeiten berechnen: $E_i = n \cdot p_i$.
- 3 Teststatistik χ^2 mit der Formel berechnen – von Hand oder per Tabellenkalkulation (siehe Kapitel *Taschenrechner*).
- 4 Freiheitsgrade bestimmen: $df = k - 1$.
- 5 Kritischen Wert für α und df aus der gegebenen Tabelle ablesen.
- 6 Vergleichen und entscheiden: Ist $\chi^2 > \chi^2_{\text{krit}}$, wird H_0 verworfen.

Beispiel: Ist der Würfel manipuliert? (Probeklausur)

Ein Würfel wird 30-mal geworfen, getestet wird mit $\alpha = 0,05$. H_0 : „Der Würfel ist fair.“

Augenzahl	1	2	3	4	5	6
Beobachtet (O_i)	0	10	10	10	0	0
Erwartet (E_i)	5	5	5	5	5	5

Erwartete Häufigkeiten: Bei einem fairen Würfel ist $p_i = 1/6$ für jede Augenzahl, also

$$E_i = 30 \cdot \frac{1}{6} = 5$$

Teststatistik: Drei Kategorien weichen um $0 - 5 = -5$ ab, drei um $10 - 5 = 5$:

$$\chi^2 = 3 \cdot \frac{(0 - 5)^2}{5} + 3 \cdot \frac{(10 - 5)^2}{5} = 15 + 15 = 30$$

Freiheitsgrade: $df = k - 1 = 6 - 1 = 5$

Kritischer Wert: Tabelle bei $\alpha = 0,05$ und $df = 5$: $\chi_{\text{krit}}^2 = 11,07$

Entscheidung: $\chi^2 = 30 > 11,07 \rightarrow H_0$ wird verworfen, der Würfel ist nicht fair.

6 R

R ist eine Programmiersprache, die speziell für Statistik und Datenvisualisierung ausgelegt ist, insbesondere durch Bibliotheken wie ggplot2. R ist kostenlos, Open Source und steht unter einer GNU-Lizenz. Als Entwicklungsumgebung kann man RStudio nutzen, da es viele nützliche Features für R mitliefert; allerdings klappt die Arbeit über Extensions auch in VS Code oder Google Colab. R ist eine interpretierte Sprache, die prozedural sowie funktional geschrieben wird, aber auch Objektorientierung unterstützt. R gibt es seit 1993.

- R ist Case Sensitive also unterscheidet Groß und Klein schreibung wird unterschieden.
- Bei R wird . als Dezimal kenzeichen genutzt, also nicht wie herkömmlich ein ,.
- Fehlende Werte als Null wird mit NA dargestellt.
- Zuweisungen erfolgen über <-
- übergaben über |>

6.1 Grundlagen

6.1.1 Datenhandling

Befehl	Erklärung
<code>filter()</code>	Beobachtung Filtern
<code>select()</code>	Variablen Wählen
<code>mutate()</code>	Variablen verändern / erzeugen
<code>case_when()</code>	Fall unterscheidung
<code>%>%</code> ; <code> ></code>	übergabe von Ergebnissen

6.1.2 Rechnen

Befehl	Erklärung
<code>+</code>	Addition
<code>-</code>	Subtraktion
<code>*</code>	Multiplikation
<code>/</code>	Division
<code>^</code>	Potenz
<code>sqrt(x)</code>	Quadratwurzel $\sqrt{x}$
<code>exp(x)</code>	Exponentialfunktion e^x
<code>log(x)</code>	Natürlicher Logarithmus $\ln(x)$

Befehl	Erklärung
<code>abs(x)</code>	Absolutbetrag $ x $

6.1.3 Logik

Befehl	Erklärung
<code>==</code>	Prüfung auf Gleichheit
<code>!=</code>	Prüfung auf Ungleichheit
<code>></code> ; <code><</code>	Größer und Kleiner
<code>>=</code> ; <code><=</code>	Größer gleich und Kleiner gleich
<code>&</code>	und
<code> </code>	oder

6.2 Datenanalyse

6.2.1 Grafische Verfahren

Befehl	Erklärung
<code>gf_bar()</code>	Säulendiagramm
<code>gf_histogram()</code>	Histogramm
<code>gf_boxplot()</code>	Boxplot
<code>gf_point()</code>	Streudiagramm
<code>mosaicplot()</code>	Mosaikplot (nicht ggformula)

`gf_*` = ggformula = ggplot2

Die `gf_*`-Befehle stammen aus dem Paket **ggformula**. Sie sind nur eine Formel-Schreibweise – `gf_point(umsatz ~ jahr, data = df)` –, die im Hintergrund ganz normale **ggplot2**-Grafiken erzeugt. Wer `gf_*` nutzt, arbeitet also bereits mit ggplot2, nur bequemer. Einzige Ausnahme oben: `mosaicplot()` gehört zu base R und **nicht** zu ggformula.

6.2.2 Kennzahlen

Befehl	Erklärung
<code>tally()</code>	Tabellierung, Häufigkeiten
<code>prop()</code>	Anteile

Befehl	Erklärung
<code>count()</code>	Anzahl
<code>diffprop()</code>	Differenz zweier Anteile
<code>favstats()</code>	Kennzahlübersicht
<code>sum()</code>	Summe
<code>diffmean()</code>	Differenz zweier Mittelwerte
<code>cor()</code>	Korrelationskoeffizient
<code>pdata()</code>	Empirische Verteilungsfunktion
<code>qdata()</code>	Quantilsfunktion

6.3 Grafik mit ggplot2

ggplot2 baut auf der *Grammar of Graphics* auf: Eine Grafik entsteht schichtweise, indem man Bausteine mit `+` aneinanderhängt. Man beschreibt also, *was* dargestellt werden soll, nicht *wie* es gezeichnet wird.

Aufbau einer ggplot-Grafik

Jede Grafik besteht aus drei Kernteilen: den **Daten**, der **Ästhetik** (`aes` : welche Variable auf welche Achse/Farbe kommt) und mindestens einer **Geometrie** (`geom_*` : Balken, Punkte, Linien ...).

```
ggplot(df, aes(x = kategorie, y = umsatz)) + # Daten + Zuordnung (aes)
  geom_col() +                               # Geometrie (Schicht)
  labs(title = "Umsatz", x = "Kategorie") +  # Beschriftung
  theme_minimal()                           # Aussehen / Design
```

6.3.1 Geometrien (`geom_*`)

Befehl	Erklärung
<code>geom_col()</code>	Balken (Werte direkt vorgegeben)
<code>geom_bar()</code>	Balken (zählt Häufigkeiten selbst)
<code>geom_line()</code>	Liniendiagramm
<code>geom_point()</code>	Streudiagramm
<code>geom_histogram(bins=30)</code>	Histogramm
<code>geom_boxplot()</code>	Boxplot

Befehl	Erklärung
<code>geom_density()</code>	Dichtekurve
<code>geom_tile()</code>	Heatmap

6.3.2 Bausteine (Layer)

Befehl	Erklärung
<code>aes()</code>	Zuordnung Variable → Achse / Farbe / ...
<code>labs()</code>	Titel und Achsenbeschriftungen
<code>facet_wrap(~ var)</code>	Kleine Vielfache: ein Panel je Gruppe
<code>facet_grid(a ~ b)</code>	Panel-Raster (Zeilen × Spalten)
<code>theme_minimal()</code>	Aussehen / Design (auch <code>theme_bw()</code> ...)
<code>scale_*_*()</code>	Achsen- und Farbskalen anpassen
<code>ggsave("plot.png")</code>	Grafik als Datei speichern

6.3.3 Ästhetik-Zuordnungen (`aes`)

Zuordnung	Erklärung
<code>x, y</code>	Position auf x- und y-Achse
<code>color</code>	Farbe (Punkte, Linien, Ränder)
<code>fill</code>	Füllfarbe (Flächen, Balken)
<code>size</code>	Größe der Elemente
<code>shape</code>	Form der Punkte
<code>alpha</code>	Transparenz (0–1)

6.4 Verteilungen & Simulation

6.4.1 Normalverteilung

Befehl	Erklärung
<code>xpnorm()</code>	Verteilungsfunktion Normalverteilung
<code>xqnorm()</code>	Quantilsfunktion Normalverteilung

Befehl	Erklärung
<code>gf_qq()</code>	QQ-Plot (allgemein)

6.4.2 Randomisierung & Simulation

Befehl	Erklärung
<code>set.seed()</code>	Zufallszahlengenerator setzen
<code>rflip()</code>	Münzwurf
<code>do() *</code>	Wiederholung (Schleife)
<code>sample()</code>	Stichprobe ohne Zurücklegen
<code>resample()</code>	Stichprobe mit Zurücklegen
<code>shuffle()</code>	Permutation

6.5 Modellierung

Befehl	Erklärung
<code>lm()</code>	Lineare Regression
<code>glm(, family="binomial")</code>	Logistische Regression
<code>residuals()</code>	Residuen
<code>fitted()</code>	Angepasste Werte
<code>predict()</code>	Vorhersagen

6.6 Inferenz

Befehl	Erklärung
<code>prop.test()</code>	Binomialtest (approximativ)
<code>xchisq.test()</code>	Chi-Quadrat-Test
<code>t.test()</code>	t-Test
<code>aov()</code>	Varianzanalyse

6.7 Daten einlesen

Befehl	Erklärung
<code>getwd()</code>	Aktuelles Arbeitsverzeichnis
<code>read.csv2("Pfad/Datei")</code>	CSV-Tabelle einlesen
<code>library(readxl)</code>	Paket für xlsx-Import laden
<code>read_excel("Pfad/Datei")</code>	xlsx-Tabelle einlesen

6.8 Tidyverse

Nicht klausurrelevant

Dieser Abschnitt ist reines Hintergrundwissen (nice-to-know) und wird in der Klausur **nicht** abgefragt. Er soll nur einordnen, woher die vielen `%>%`-, `gf_*`- und `str_*`-Befehle eigentlich kommen.

Das *Tidyverse* ist kein einzelnes Paket, sondern eine Sammlung von R-Paketen, die eine gemeinsame Philosophie und einheitliche Syntax teilen. Alle sind mit einem einzigen `library(tidyverse)` geladen.

6.8.1 Historie

Jahr	Meilenstein
2007	<i>ggplot2</i> erscheint (Hadley Wickham) und setzt die Grammar of Graphics um
2014	<i>dplyr</i> löst das ältere <i>plyr</i> ab; Wickhams Aufsatz <i>Tidy Data</i> prägt die Idee
2016	Das Meta-Paket <i>tidyverse</i> bündelt die Einzelpakete unter einem Dach
2022	RStudio benennt sich in <i>Posit</i> um und pflegt das Tidyverse weiter

Tidy Data

Das Ordnungsprinzip hinter dem Tidyverse: **jede Variable** ist eine Spalte, **jede Beobachtung** eine Zeile, **jede Beobachtungseinheit** eine Tabelle.

6.8.2 Kern-Pakete

Paket	Zweck
<code>dplyr</code>	Datentransformation (<code>filter</code> , <code>select</code> , <code>mutate</code> , <code>summarise</code>)
<code>tidyr</code>	Daten umstrukturieren (<code>pivot_longer</code> / <code>pivot_wider</code>)
<code>ggplot2</code>	Visualisierung (Grammar of Graphics)
<code>readr</code>	Dateien einlesen (<code>read_csv</code>)

Paket	Zweck
<code>tibble</code>	Moderne Variante des <code>data.frame</code>
<code>purrr</code>	Funktionales Programmieren (<code>map</code>)
<code>stringr</code>	Strings bearbeiten (<code>str_*</code>)
<code>forcats</code>	Faktoren / Kategorien (<code>fct_*</code>)
<code>lubridate</code>	Datum und Uhrzeit

Was ist ein tibble?

Ein **tibble** ist die moderne Tabelle des Tidyverse – im Kern ein `data.frame`, nur angenehmer im Umgang:

- Es druckt in der Konsole nur die ersten 10 Zeilen und zeigt zusätzlich jeden **Spaltentyp** an (`<dbl>`, `<chr>` ...).
- Es wandelt Text **nicht** heimlich in Faktoren um.
- Es warnt bei unbekannten Spaltennamen, statt still `NULL` zurückzugeben.

Erzeugt wird es mit `tibble(...)` oder aus einer bestehenden Tabelle per `as_tibble(df)`.

7 Taschenrechner: Casio fx-991DE X ClassWiz

Der *Casio fx-991DE X ClassWiz* ist in der Klausur zugelassen – und er kann deutlich mehr als Plus und Mal: alle Kennwerte einer Stichprobe, lineare Regression samt Korrelationskoeffizient, kumulierte Normalverteilung und mit einem kleinen Trick sogar Chi-Quadrat. Dieses Kapitel zeigt die Handgriffe Schritt für Schritt; alle Anzeigen sind dem Original-Display nachgebaut.




Abbildung 7. Casio fx-991DE X ClassWiz

Die wichtigsten Tasten

Taste	Funktion
MENU	öffnet das Hauptmenü – von hier erreichst du alle Modi
OPTN	Optionen des aktuellen Modus, z. B. die Kennwerte-Berechnung
SHIFT	Zweitbelegung einer Taste (gelbe Beschriftung)
ALPHA	Drittbelegung (rot), u. a. Buchstaben und = für Formeln
=	Eingabe bestätigen bzw. Ergebnis berechnen
AC	Eingabe verwerfen, zurück zum Eingabebildschirm
S$\leftrightarrow$D	schaltet ein Ergebnis zwischen Bruch und Dezimalzahl um

Für die Klausur brauchst du nur drei Menüs. Diese Tabelle ist der Wegweiser durchs Kapitel:

Aufgabe in der Klausur	Menü	Abschnitt
Mittelwert, Median, Quartile, Standardabweichung	6: Statistik	Abschnitt 7.1
Regressionsgerade und Korrelationskoeffizient r	6: Statistik	Abschnitt 7.3
Summen, Zwischenrechnungen, eigene Formeln	8: Tabellenkalk.	Abschnitt 7.2
Wahrscheinlichkeiten der Normalverteilung	7: Verteilungsfkt.	Abschnitt 7.4
Chi-Quadrat-Wert aufsummieren	8: Tabellenkalk.	Abschnitt 7.5

Kein QR-Code in der Klausur

Die Original-Doku bewirbt an mehreren Stellen die Online-Visualisierung per QR-Code, etwa um Box-Plots anzuzeigen. Dafür braucht es ein Smartphone – in der Klausur fällt das also aus. Den Box-Plot zeichnest du stattdessen von Hand: Alle fünf Werte dafür (Minimum, Q_1 , Median, Q_3 , Maximum) liefert die Kennwerte-Berechnung aus Abschnitt 7.1.

7.1 Stichprobe und Kennwerte (Menü 6: Statistik)

Ein Durchlauf, alle Kennwerte

Stichprobe einmal in Menü 6: Statistik eintippen, dann **OPTN** → **3** drücken: Der Rechner liefert Mittelwert, Median, beide Quartile, Minimum, Maximum und Standardabweichung in einer einzigen Liste.

7.1.1 Stichprobe eingeben

Als Beispiel dient die Stichprobe aus der Taschenrechner-Doku: 39, 72, 23, 22, 24, 23, 16, 21, 16, 19.

- 1 **MENU** → **6** öffnet das Statistik-Menü.
- 2 **1** wählt 1: 1-Variable – eine Messreihe ohne zweite Variable.
- 3 Jeden Wert eintippen und mit **=** bestätigen; der Cursor springt automatisch in die nächste Zeile.

1:1-Variable
2:y=a+bx
3:y=a+bx+cx²
4:y=a+b·ln(x)

Typ-Auswahl nach **MENU** → **6**

	x
1	39
2	72
3	23
4	22

Werteliste im Statistik-Editor
(Ausschnitt)

7.1.2 Kennwerte ablesen

- 1 **OPTN** öffnet die Optionen des Statistik-Menüs.
- 2 **3** wählt 3: 1-Variab-Berech – alle Kennwerte erscheinen als Liste.

1:Typ auswählen
2:Editor
3:1-Variab-Berech
4:Statistik-Rechn

Optionen nach **OPTN**

$\bar{x}$	27,5
Σx	275
Σx^2	10137
σx	16,04524852
$s x$	16,91317698
n	10
min(x)	16
Q1	19
Med	22,5
Q3	24
max(x)	72

Ergebnisliste (auf dem Gerät mit **▼** scrollen)

So übersetzt du die Anzeige in die Begriffe aus dem Kapitel *Deskriptive Statistik*:

Anzeige	Bedeutung	Bezug zum Lernzettel
$\bar{x}$	Mittelwert	Lagemaße
$\Sigma x, \Sigma x^2$	Summe der Werte bzw. ihrer Quadrate	Zwischenwerte für die Varianz „von Hand“

Anzeige	Bedeutung	Bezug zum Lernzettel
σx	Standardabweichung (geteilt durch n)	entspricht unserem S
sx	korrigierte Standardabweichung ($n - 1$)	brauchen wir nicht
n	Anzahl der Werte	–
$\min(x), \max(x)$	kleinster bzw. größter Wert	Spannweite = $\max - \min$
Med	Median	Lagemaße
Q_1, Q_3	unteres bzw. oberes Quartil	$IQR = Q_3 - Q_1$, Box-Plot

 σx oder sx ?

Der Rechner zeigt zwei Standardabweichungen an. Unsere Varianz-Formel teilt durch n – in der Klausur liest du also σx ab. Das daneben stehende sx teilt durch $n - 1$ und gehört zur Inferenzstatistik; es wäre hier falsch.

Häufigkeitstabellen

Liegt die Stichprobe als Häufigkeitstabelle vor (Wert und Anzahl), schalte die Häufigkeitsspalte ein: **SHIFT** → **MENU** → Statistik → Häufigkeit Ein. Der Editor bekommt dann eine zweite Spalte **Häufig** für die Anzahl je Wert – die Kennwerte-Berechnung funktioniert genauso.

7.2 Tabellenkalkulation (Menü 8)

Menü 8: Tabellenkalk. ist ein Mini-Excel mit fünf Spalten (A–E) und 45 Zeilen – praktisch für Zwischenrechnungen, Summen und alles, wofür es kein fertiges Menü gibt.

7.2.1 Werte eingeben und auswerten

- 1** **MENU** → **8** öffnet die Tabellenkalkulation.
- 2** Werte in Spalte A eintippen, jeden mit **=** bestätigen.
- 3** Cursor auf eine leere Zelle setzen, **OPTN** drücken und z. B. 1: Minimum wählen.
- 4** Den Bereich angeben, etwa A1:A6 (Buchstaben über **ALPHA**), und mit **=** bestätigen.

	A	B	C
1	19		
2	12		
3	23		
4	22		
5	16		
6	21		

Stichprobe in Spalte A

1:Minimum
2:Maximum
3:Mittelwert
4:Summe

Auswahl nach **OPTN** (Aus-
schnitt)

	A	B	C
1	19		
2	12		
3	23		
4	22		
5	16		
6	21		
7	12		

Min(A1:A6)

Ergebnis in Zelle A7

Genauso liefern 3: Mittelwert → Mean(A1:A6) den Wert 18,8333 und 4: Summe → Sum(A1:A6) den Wert 113.

7.2.2 Eigene Formeln und „Formel füllen“

Formeln funktionieren wie in Excel: Sie beginnen mit $=$, das du über **ALPHA** → **CALC** eingibst, und rechnen mit Zellbezügen. $=A1+5$ in Zelle B1 addiert also 5 auf den Wert aus A1.

Damit du eine Formel nicht sechsmal eintippen musst, gibt es **OPTN** → **Formel füllen**: Die Formel wird in einen ganzen Bereich kopiert, die Zellbezüge wandern automatisch mit – aus $=A2+5$ wird in Zeile 3 ein $=A3+5$ und so weiter.

Formel füllen
 Formel= $A2+5$
 Zellen:B2:B6

	A	B	C
1	19	24	
2	12	17	
3	23	28	
4	22	27	
5	16	21	
6	21	26	

$=A2+5$

Dialog „Formel füllen“

Spalte B nach dem Füllen

Erst ablesen, dann Menü wechseln

Die Tabellenkalkulation hat keinen Speicher: Beim Wechsel in ein anderes Menü oder beim Ausschalten sind alle Zellen leer. Ergebnisse also notieren, bevor du weatherspringst.

7.3 Lineare Regression und Korrelation (Menü 6: $y=a+bx$)

Zusammenhangsmaße laufen über dasselbe Statistik-Menü wie die Kennwerte – nur wählst du als Typ 2: $y=a+bx$. Der Editor bekommt dann zwei Spalten für die Wertepaare (x, y) .

- 1 **MENU** → **6** → **2** – Statistik-Menü mit Typ 2: $y=a+bx$.
- 2 Erst alle x -Werte eingeben, dann mit den Pfeiltasten in die y -Spalte wechseln und die y -Werte eintippen.
- 3 **OPTN** → **4** wählt 4: Regressions-Berech – der Rechner zeigt a , b und r .

Untersucht wird, wie der Angebotspreis y (in €) mit der Absatzmenge x zusammenhängt:

Zahlenpaar	1	2	3	4
Absatzmenge x	109	98	109	94
Angebotspreis y	7,3	7,7	9	6,6

	x	y
1	109	7,3
2	98	7,7
3	109	9
4	94	6,6

Wertepaare im Editor

$y=a+bx$	
a	-1,152259887
b	0,0858757062
r	0,6541947207

Ergebnis von Regressions-Berech

Beispiel: Angebotspreis und Absatzmenge (aus der Doku)

Die Regressionsgerade lautet also $y = -1,1523 + 0,0859 \cdot x$. Der Korrelationskoeffizient $r = 0,654$ zeigt eine mittelstarke positive Korrelation – wie du r einordnest, steht im Abschnitt *r-Wert* des Kapitels *Deskriptive Statistik*.

7.4 Normalverteilung (Menü 7: Verteilungsfkt.)

Die kumulierte Normalverteilung – also die Wahrscheinlichkeit, dass X zwischen zwei Grenzen liegt – rechnet Menü 7: Verteilungsfkt. direkt aus, ganz ohne z-Transformation und Tabelle.

- 1 **MENU** → **7** öffnet die Verteilungsfunktionen.
- 2 **2** wählt 2: Kumul. Normal-V.
- 3 Vier Werte eintragen, jeweils mit **=**: untere Grenze, obere Grenze, σ und μ .
- 4 Noch einmal **=** drücken – der Rechner zeigt P .

Reihenfolge der Eingabe

Nach den beiden Grenzen fragt der Rechner erst σ und dann μ ab – nicht andersherum. Wer die beiden vertauscht, bekommt ohne Fehlermeldung ein falsches Ergebnis.

Einseitige Wahrscheinlichkeiten baust du über die Grenzen nach:

Gesucht	untere Grenze	obere Grenze
$P(a \leq X \leq b)$ – zwischen zwei Grenzen	a	b
$P(X \leq b)$ – höchstens b	sehr klein wählen	b
$P(X \geq a)$ – mindestens a	a	sehr groß wählen

„Sehr klein“ bzw. „sehr groß“ heißt: deutlich außerhalb aller plausiblen Werte – die Doku nennt das eine Notlösung. Unten reicht oft 0 (wenn keine negativen Werte vorkommen), oben z. B. 10 000.

Beispiel: Abfüllanlage mit $\mu = 354$ und $\sigma = 10,28$

Eine Anlage füllt Flaschen im Mittel mit $\mu = 354$ ml bei einer Standardabweichung von $\sigma = 10,28$ ml (Beispiel aus der Doku).

Kumul. Normal-V	
Untere:	360
Obere:	400
σ :	10,28
μ :	354

Eingabemaske für Fall a)

P=	0,2797215279
----	--------------

Ergebnis für Fall a)

Gesucht	untere	obere	Ergebnis
a) $P(360 \leq X \leq 400)$	360	400	0,2797
b) $P(X \leq 360)$	0	360	0,7203
c) $P(X \geq 360)$	360	10 000	0,2797

Rechenweg trotzdem hinschreiben

In der Klausur zählt der Weg über die z-Transformation und die Normalverteilungstabelle (Kapitel *Normalverteilung*) – der Rechner dient zur Kontrolle. Für Fall b) von oben: $z = (360 - 354) / 10,28 \approx 0,58$, Tabelle: $\Phi(0,58) = 0,7190$. Die kleine Abweichung zum Rechnerwert 0,7203 kommt nur vom Runden auf $z = 0,58$.

7.5 Chi-Quadrat mit der Tabellenkalkulation

Für den Chi-Quadrat-Test hat der fx-991DE X kein eigenes Menü. Die Teststatistik

$$\chi^2 = \sum_{i=1}^k \frac{(B_i - E_i)^2}{E_i}$$

mit den beobachteten Häufigkeiten B_i und den erwarteten Häufigkeiten E_i baust du aber in drei Schritten in der Tabellenkalkulation aus Abschnitt 7.2 auf. Die Theorie dazu – Hypothesen, Freiheitsgrade, kritischer Wert – steht im Kapitel *Inferenzstatistik*; hier geht es nur um den Rechenweg.

- 1 Beobachtete Häufigkeiten in Spalte A eintippen, erwartete in Spalte B.
- 2 **OPTN** → Formel füllen mit Formel $= (A1-B1)^2 \div B1$ und Zellen C1:C6 – Spalte C enthält danach alle Einzelbeiträge.
- 3 Die Summe in eine freie Zelle holen: $= \text{Sum}(C1:C6)$ ergibt den Chi-Quadrat-Wert.

Beispiel: Ist der Würfel fair?

Ein Würfel wird 120-mal geworfen. Bei einem fairen Würfel erwartet man $120 / 6 = 20$ Würfe pro Augenzahl; beobachtet werden 25, 17, 15, 23, 24 und 16.

	A	B	C
1	25	20	1,25
2	17	20	0,45
3	15	20	1,25
4	23	20	0,45
5	24	20	0,8
6	16	20	0,8
7			5

$=\text{Sum}(C1:C6)$

Spalte C per „Formel füllen“, Summe in C7

Der Rechner liefert $\chi^2 = 5$. Ob das „viel“ ist, entscheidet der Vergleich mit dem kritischen Wert aus der Chi-Quadrat-Tabelle (bei $k - 1 = 5$ Freiheitsgraden und $\alpha = 0,05$ liegt er bei 11,07) – hier gibt es also keinen Hinweis, dass der Würfel unfair ist.

8 Formelsammlung

Auf einen Blick

Diese Formelsammlung fasst **sämtliche Formeln** aus den vorherigen Kapiteln kompakt zusammen – ideal zum schnellen Nachschlagen in der Klausur. Am Ende folgt die **Normalverteilungstabelle**. Sie wird in der Klausur gestellt und ist hier nur der Vollständigkeit halber noch einmal abgedruckt.

Notation: $\bar{x}$ ist der Mittelwert (Erwartungswert μ), n die Anzahl der Werte, $x_{(i)}$ der Wert an Position i der aufsteigend sortierten Liste.

8.1 Deskriptive Statistik

8.1.1 Lage- und Streuungsmaße

Größe	Formel	Bedeutung
Mittelwert	$\bar{x} = \frac{\sum_{i=1}^n x_i}{n}$	durchschnittlicher Wert
MAD	$\text{MAD} = \frac{\sum_{i=1}^n \bar{x} - x_i }{n}$	mittlere absolute Abweichung vom Mittelwert
Varianz	$S^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n}$	mittlere quadratische Streuung (auch σ^2); Einheit quadriert
Standardabweichung	$S = \sqrt{S^2}$	Streuung in der Origineleinheit (auch σ)
Spannweite	$R = x_{\max} - x_{\min}$	Abstand von größtem und kleinstem Wert
IQR	$\text{IQR} = Q_3 - Q_1$	Breite des Bereichs der mittleren 50 % der Daten

8.1.2 Quantile

Für ein p -Quantil ($0 < p < 1$) werden die Werte zuerst aufsteigend sortiert:

$$x_p = \begin{cases} x_{(\lceil n \cdot p \rceil)} & \text{falls } n \cdot p \notin \mathbb{Z} \\ \frac{1}{2} \cdot (x_{(n \cdot p)} + x_{(n \cdot p + 1)}) & \text{falls } n \cdot p \in \mathbb{Z} \end{cases}$$

$$Q_1 = x_{0.25} \quad Q_2 = x_{0.5} = \text{Median} \quad Q_3 = x_{0.75}$$

8.1.3 Zusammenhangsmaße

Kovarianz – misst, wie zwei Variablen gemeinsam um ihren Mittelwert streuen (positiv = gleichläufig, negativ = gegenläufig):

$$S_{xy} = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

Korrelationskoeffizient r – Stärke und Richtung eines linearen Zusammenhangs, $-1 \leq r \leq +1$ (Betrag = Stärke, Vorzeichen = Richtung):

$$r = \frac{S_{xy}}{S_x \cdot S_y}$$

8.2 Wahrscheinlichkeit & Normalverteilung

Größe	Formel	Bedeutung
z-Transformation	$z = \frac{x-\mu}{\sigma}$	beliebige Verteilung $\rightarrow$ Standardnormalverteilung ($\mu = 0, \sigma = 1$); nötig für die Tabelle
Symmetrie	$\Phi(-u) = 1 - \Phi(u)$	negative u -Werte aus der Tabelle bestimmen

Nur zur Vollständigkeit

Die folgenden beiden Funktionen müssen wir **nicht** auswendig können – dafür gibt es die z -Transformation und die Tabelle.

Dichtefunktion (Höhe der Glockenkurve an der Stelle x):

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

Verteilungsfunktion (kumulierte Wahrscheinlichkeit $P(X \leq x)$):

$$F(x) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(u-\mu)^2}{2\sigma^2}} du$$

8.3 Inferenzstatistik – Chi-Quadrat-Test

$$\chi^2 = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i} \quad E_i = n \cdot p_i \quad \text{df} = k - 1$$

Zeichen	Bedeutung
O_i	beobachtete Häufigkeit (<i>observed</i>) in Kategorie i
E_i	erwartete Häufigkeit (<i>expected</i>) in Kategorie i : $E_i = n \cdot p_i$
k	Anzahl der Kategorien
n	Gesamtzahl der Beobachtungen
df	Freiheitsgrade (<i>degrees of freedom</i>): $\text{df} = k - 1$

Entscheidungsregel

$$\begin{aligned} \chi^2 > \chi_{\text{krit}}^2 &\rightarrow H_0 \text{ verwerfen: Die Abweichung ist signifikant.} \\ \chi^2 \leq \chi_{\text{krit}}^2 &\rightarrow H_0 \text{ nicht verwerfen: kein Nachweis einer Abweichung.} \end{aligned}$$

Den kritischen Wert χ_{krit}^2 liest du aus der Chi-Quadrat-Tabelle an der Kreuzung von Signifikanzniveau α (meist 0,05) und Freiheitsgraden df ab.

8.4 Normalverteilungstabelle

Die Tabelle gibt $\Phi(u) = P(Z \leq u)$ für die Standardnormalverteilung an. Der u -Wert setzt sich aus der Zeile (erste Nachkommastelle) und der Spalte (zweite Nachkommastelle) zusammen.

Negativen Wert berechnen

$$\Phi(-u) = 1 - \Phi(u)$$

Tabelle

u	0,00	0,01	0,02	0,03	0,04	0,05	0,06	0,07	0,08	0,09	u
0,0	0,5000	0,5040	0,5080	0,5120	0,5160	0,5199	0,5239	0,5279	0,5319	0,5359	0,0
0,1	0,5398	0,5438	0,5478	0,5517	0,5557	0,5596	0,5636	0,5675	0,5714	0,5753	0,1
0,2	0,5793	0,5832	0,5871	0,5910	0,5948	0,5987	0,6026	0,6064	0,6103	0,6141	0,2
0,3	0,6179	0,6217	0,6255	0,6293	0,6331	0,6368	0,6406	0,6443	0,6480	0,6517	0,3
0,4	0,6554	0,6591	0,6628	0,6664	0,6700	0,6736	0,6772	0,6808	0,6844	0,6879	0,4
0,5	0,6915	0,6950	0,6985	0,7019	0,7054	0,7088	0,7123	0,7157	0,7190	0,7224	0,5
0,6	0,7257	0,7291	0,7324	0,7357	0,7389	0,7422	0,7454	0,7486	0,7517	0,7549	0,6
0,7	0,7580	0,7611	0,7642	0,7673	0,7704	0,7734	0,7764	0,7794	0,7823	0,7852	0,7
0,8	0,7881	0,7910	0,7939	0,7967	0,7995	0,8023	0,8051	0,8079	0,8106	0,8133	0,8
0,9	0,8159	0,8186	0,8212	0,8238	0,8264	0,8289	0,8315	0,8340	0,8365	0,8389	0,9
1,0	0,8413	0,8438	0,8461	0,8485	0,8508	0,8531	0,8554	0,8577	0,8599	0,8621	1,0
1,1	0,8643	0,8665	0,8686	0,8708	0,8729	0,8749	0,8770	0,8790	0,8810	0,8830	1,1
1,2	0,8849	0,8869	0,8888	0,8907	0,8925	0,8944	0,8962	0,8980	0,8997	0,9015	1,2
1,3	0,9032	0,9049	0,9066	0,9082	0,9099	0,9115	0,9131	0,9147	0,9162	0,9177	1,3
1,4	0,9192	0,9207	0,9222	0,9236	0,9251	0,9265	0,9279	0,9292	0,9306	0,9319	1,4
1,5	0,9332	0,9345	0,9357	0,9370	0,9382	0,9394	0,9406	0,9418	0,9429	0,9441	1,5
1,6	0,9452	0,9463	0,9474	0,9484	0,9495	0,9505	0,9515	0,9525	0,9535	0,9545	1,6
1,7	0,9554	0,9564	0,9573	0,9582	0,9591	0,9599	0,9608	0,9616	0,9625	0,9633	1,7
1,8	0,9641	0,9649	0,9656	0,9664	0,9671	0,9678	0,9686	0,9693	0,9699	0,9706	1,8
1,9	0,9713	0,9719	0,9726	0,9732	0,9738	0,9744	0,9750	0,9756	0,9761	0,9767	1,9
2,0	0,9773	0,9778	0,9783	0,9788	0,9793	0,9798	0,9803	0,9808	0,9812	0,9817	2,0
2,1	0,9821	0,9826	0,9830	0,9834	0,9838	0,9842	0,9846	0,9850	0,9854	0,9857	2,1
2,2	0,9861	0,9864	0,9868	0,9871	0,9875	0,9878	0,9881	0,9884	0,9887	0,9890	2,2
2,3	0,9893	0,9896	0,9898	0,9901	0,9904	0,9906	0,9909	0,9911	0,9913	0,9916	2,3
2,4	0,9918	0,9920	0,9922	0,9925	0,9927	0,9929	0,9931	0,9932	0,9934	0,9936	2,4
2,5	0,9938	0,9940	0,9941	0,9943	0,9945	0,9946	0,9948	0,9949	0,9951	0,9952	2,5
2,6	0,9953	0,9955	0,9956	0,9957	0,9959	0,9960	0,9961	0,9962	0,9963	0,9964	2,6
2,7	0,9965	0,9966	0,9967	0,9968	0,9969	0,9970	0,9971	0,9972	0,9973	0,9974	2,7
2,8	0,9974	0,9975	0,9976	0,9977	0,9977	0,9978	0,9979	0,9979	0,9980	0,9981	2,8
2,9	0,9981	0,9982	0,9983	0,9983	0,9984	0,9984	0,9985	0,9985	0,9986	0,9986	2,9

Quantiltabelle

Die Quantiltabelle liefert den umgekehrten Weg: zu einer Wahrscheinlichkeit p den zugehörigen u -Wert u_p (mit $\Phi(u_p) = p$).

p	0,8	0,9	0,95	0,975	0,98	0,99	0,995
u_p	0,84162	1,28155	1,6449	1,9600	2,0538	2,3264	2,5758